

亓庆国

浙江大学博士研究生 · 大模型高效架构与长上下文 · 研究型实习（杭州；随时到岗，每周4-5天，可实习6个月以上）

☎ 18918275072 | ✉ qiqingguo@zju.edu.cn | 🏠 oncemoe.github.io | 📧 oncemoe

教育经历

浙江大学-计算机科学与技术学院（博士）

研究方向：大模型高效架构与长上下文建模；预计2028年毕业；CCF-A类会议第一作者论文2篇

浙江杭州

2024.09-至今

中国科学院大学-杭州高等研究院（硕士）

研究方向：动态图神经网络与大规模图学习；优秀毕业生

浙江杭州

2021.09-2024.06

同济大学-软件学院（本科）

学习奖学金二等奖

上海

2011.09-2015.06

科研成果

- QingGuo Qi et al. SCOPE: Boosting LLM Efficiency with Scoped Position Encoding. ACL 2026 (CCF-A, 第一作者) .
- QingGuo Qi et al. Input Snapshots Fusion for Scalable Discrete-Time Dynamic Graph Neural Networks. KDD 2025 (CCF-A, 第一作者) .
- 发明专利（第一发明人），一种预测方法、装置、可读存储介质及电子设备，CN202310405190.4，已授权
- 发明专利（第一发明人），基于三维全连接融合的时序数据预测方法及模型训练方法，CN202311702608.4，已授权

科研经历

SCOPE：面向长上下文的隐式位置编码与高效注意力

浙江大学/之江实验室

博士研究生 · 第一作者

2024.09-至今

- 针对长上下文计算开销与位置外推问题，提出多尺度注意力范围驱动的隐式位置编码，以结构化稀疏实现序列顺序建模与计算优化。
- 理论分析与实验验证表明，多层scoped attention可形成层级序列处理机制，顺序感知范围随深度指数增长，无需显式位置信号。
- 基于TorchTitan完成LLaMA-3-8B架构50B tokens从零预训练及4K→32K→128K上下文扩展，实现FlexAttention/Triton训推内核。
- 在相应配置下，Attention FLOPs 理论上可降至稠密注意力的约 1/8；256K 上下文下，端到端 prefill 较 RoPE 基线加速约 2×。
- 128K 上下文“大海捞针”检索平均准确率达到 92%，高于 RoPE 基线的 86%，验证稀疏计算下的长距离信息检索能力。

SFDyG：可扩展离散动态图神经网络

中国科学院大学/之江实验室

硕士/博士 · 第一作者

2022.07-2025.08

- 针对多快照动态图的重复计算与显存开销，提出输入快照融合方法，将历史快照统一为带时间属性的多重图。
- 基于 Hawkes 过程设计时间衰减消息传递机制，联合建模图结构与时间依赖，并支持小批量训练。
- 在 8 个公开动态图数据集上取得优于基线的链接预测结果；Stack Overflow 上小批量训练较全批量显存占用降低约 44%。

工作与实习经历

之江实验室

研究实习生

LLM Architecture / AI4Science（高效大模型架构、图机器学习）

2022.07-至今

- 参与OGB-LSC NeurIPS 2022论文分类赛道，基于R-GAT结合PCA降维与SGC预处理构建大规模异构图模型，团队获全球第5名。
- 针对动态图节点属性预测，提出三维全连接混合网络，融合特征、空间与时间信息，提升预测效果与计算效率，相关发明专利已授权。

大众点评、小红书等互联网企业

上海

数据开发

2015-2021

- 使用Hive/Hadoop处理App业务数据并制作可视化报表。

技能

技能 Python、C++；PyTorch、Transformers、TorchTitan；FlexAttention、Triton；PyG、Git、Linux

外语 CET-6（582分），具备英文论文阅读与写作能力

荣誉奖励

2022.11 OGB-LSC NeurIPS 2022 大规模图学习竞赛（论文分类赛道）

全球第5名

2022.12 杭州高等研究院研究生学业奖学金

一等奖

2024.05 杭州高等研究院

优秀毕业生

2025.10 浙江大学计算机科学与技术学院

优秀研究生